أسئلة وأجوبة المناقشة

رسالة ماجستير — حسين ناصر حسين
جامعة دامغان — علوم الحاسوب (الحوسبة اللينة والذكاء الاصطناعي)
إشراف: د. عبد العلي بصيري — مايو 2026

أسئلة عامة عن الرسالة

س: ما هو موضوع رسالتك بالضبط؟

ج: الرسالة تطوّر طريقة هجينة تجمع بين خوارزمية تحسين سرب الجسيمات (PSO) والخوارزمية الجينية (GA) لاختيار مجموعة السمات الفعّالة، ثم تُقيّم المجموعة المختارة بمصنّف الغابة العشوائية (Random Forest) على مجموعتي بيانات: Spambase لكشف البريد المزيف، و Phishing Websites لكشف المواقع المزيفة.

س: لماذا اخترت هذا الموضوع؟

ج: لأن البيانات الحديثة تحتوي على عدد ضخم من السمات، وكثير منها غير مهم أو مكرّر. هذا يزيد التعقيد الحسابي ويبطئ المعالجة ويخفض دقة النماذج. اختيار السمات يعالج هذه المشكلة مباشرة، والطريقة الهجينة تعطي نتائج أفضل من كل خوارزمية منفردة.

س: ما الفرق بين PSO و GA، ولماذا جمعتهما؟

ج: PSO سريع في البحث ويستفيد من أفضل حل وجده كل جسيم وأفضل حل في السرب كله، لكنه قد يقع في حل مثالي محلي. و GA يحافظ على تنوّع المجتمع عبر التقاطع والطفرة، لكنه أبطأ في التقارب. الجمع بينهما يعطي سرعة PSO مع قدرة GA على تجنّب الحلول المحلية.

س: ما الجديد في رسالتك مقارنة بالأعمال السابقة؟

ج: التوليفة المحددة للمعاملات، وآلية الإصلاح التي تجبر كل حل على حمل العدد المطلوب بالضبط من السمات، والأرشيف الخارجي الذي يمنع تكرار الحلول المتشابهة، ثم التحقق على مجموعتين مختلفتين تماماً (بيانات نصية عددية وبيانات وصفية ثلاثية القيم).

أسئلة عن مجموعات البيانات

س: ما مجموعة Spambase ومن أين أتت؟

ج: من قاعدة UCI Machine Learning Repository. تحتوي على 4601 رسالة بريد إلكتروني، كل رسالة موصوفة بـ 57 سمة عددية: 48 سمة هي تكرار كلمة معينة بالنسبة المئوية، و6 سمات هي تكرار محرف معين، و3 سمات هي متوسط وطول وأكبر عدد من الأحرف الكبيرة المتتالية. الفئة 1 تعني بريد مزعج، والفئة 0 تعني بريد سليم.

س: ما مجموعة Phishing Websites؟

ج: أيضاً من UCI. تحتوي على 11055 موقعاً، كل موقع موصوف بـ 30 سمة، وكل سمة تأخذ القيمة -1 أو 0 أو 1. الفئة 1 تعني موقع تصيّد (مزيف)، والفئة -1 تعني موقع سليم.

س: كم عدد السمات التي اختارتها الخوارزمية؟

ج: في Spambase اختارت 46 سمة من أصل 57. وفي Phishing اختارت 22 سمة من أصل 30. أي أننا حذفنا 11 سمة و8 سمات على التوالي دون خسارة ملحوظة في الدقة.

س: لماذا استخدمت مجموعتين وليس واحدة؟

ج: لأن التحقق على مجموعتين مختلفتين في الطبيعة والحجم يثبت أن الطريقة ليست ملائمة لمجموعة واحدة بعينها، بل قابلة للتعميم. وهذا يقوّي الاستنتاج.

أسئلة عن الخوارزمية

س: اشرح خطوات الخوارزمية الهجينة.

ج: أولاً نرمّز الحل: كروموسوم ثنائي بطول عدد السمات، حيث 1 يعني السمة مختارة و0 تعني محذوفة. ثانياً نبدأ بمجتمع عشوائي. ثالثاً نحدّث سرعة كل جسيم بالمعادلة 3-2، نحوّل السرعة إلى احتمال بدالة sigmoid (المعادلة 3-3)، ثم نحوّلها إلى قيمة ثنائية (المعادلة 3-4). رابعاً نطبّق التقاطع لإنتاج أبناء من أبوين. خامساً نطبّق الطفرة لتغيير بتات مفردة. سادساً نطبّق دالة الإصلاح ليحمل كل حل العدد المطلوب بالضبط. سابعاً نحفظ أفضل حل في الجيل التالي (النخبة) ونحدّث الأرشيف الخارجي. ونكرّر ذلك 20 تكراراً.

س: ما هي دالة الكلفة؟

ج: الكلفة تساوي (1 - الدقة) زائد معامل صغير مضروب في عقوبة عدد السمات. الحد الأول يقلّل خطأ التصنيف، والحد الثاني يقلّل حجم المجموعة. المعادلة 3-5 في الرسالة تكتب العقوبة كنسبة حجم المجموعة المختارة إلى حجم كل السمات، وشيفرة MATLAB تحسبها كنسبة العدد المختار إلى العدد المطلوب. القيمتان متقاربتان لأن العدد المطلوب قريب من عدد السمات الفعّالة.

س: ما هي دالة الإصلاح ولماذا نحتاجها؟

ج: لأن المعاملات العشوائية قد تنتج حلاً بعدد سمات مختلف عن العدد المطلوب. دالة الإصلاح (repair_solution.m) تضيف بتات أو تحذف بتات عشوائياً حتى يصبح العدد مطابقاً تماماً، فيكون كل الحلول قابلة للمقارنة على أساس واحد.

س: ما دور الأرشيف الخارجي؟

ج: يحفظ أفضل الحلول التي ظهرت خلال كل التنفيذ، ويمنع تكدّس الحلول المتشابهة أو المكرّرة في المجتمع. هذا يحافظ على التنوّع ويسرّع التقارب.

س: لماذا استخدمت دالة sigmoid؟

ج: لأن فضاء البحث ثنائي (كل سمة إما مختارة أو محذوفة)، لكن سرعة PSO قيمة حقيقية مستمرة. دالة sigmoid تحوّل هذه القيمة الحقيقية إلى احتمال بين 0 و1، ثم نقارنها بعدد عشوائي لنحصل على 0 أو 1. هذا هو المعيار في PSO الثنائي.

س: كم استغرقت الخوارزمية من الوقت؟

ج: يعتمد على حجم البيانات وعدد التكرارات. على Spambase بـ 20 تكراراً وحجم مجتمع 10، تنتهي العملية في دقائق على حاسوب عادي. الغابة العشوائية تُدرَّب داخل دالة اللياقة، وهذا هو الجزء الأغلى.

أسئلة عن النتائج

س: ما أفضل نتيجة حصلت عليها؟

ج: على Phishing Websites: دقة 98.20%، إحكام 97.98%، استدعاء 98.80%، F1 يساوي 98.39%، والمساحة تحت منحنى ROC تساوي 0.996. وعلى Spambase: دقة 96.79%، إحكام 96.40%، استدعاء 97.89%، F1 يساوي 97.14%، والمساحة تحت المنحنى 0.988.

س: ماذا يعني AUC = 0.996؟

ج: يعني أن النموذج يفصل بين الفئتين بشكل شبه مثالي. القيمة 1.0 فصل كامل، و0.5 تخمين عشوائي. فالقيمة 0.996 تعني احتمالاً 99.6% أن يُعطي النموذج درجة أعلى لعيّنة موجبة من عيّنة سالبة عشوائية.

س: هل حذف السمات قلّل الدقة؟

ج: لا، بل رفع الدقة أو حافظ عليها. وهذا هو جوهر النتيجة: عدد أقل من السمات مع دقة أعلى أو مساوية، أي تعقيد حسابي أقل وسرعة أكبر.

س: كيف تعرف أن النموذج لم يحفظ البيانات (overfitting)؟

ج: لأننا نقسم البيانات إلى تدريب واختبار، والاختبار لا يُلمَس إلا في النهاية. وذكرت في الرسالة التحقق المتقاطع الخماسي لمنع الإفراط في التعلّم. الفرق الصغير بين دقة التدريب ودقة الاختبار يدل على أن النموذج يعمّم ولا يحفظ.

س: لماذا تختلف النتائج قليلاً عند إعادة التشغيل؟

ج: لأن الخوارزمية عشوائية: المجتمع الأولي عشوائي، وأعداد r1 و r2 عشوائية، والطفرة عشوائية، والغابة العشوائية نفسها تستخدم عشوائية في بناء الأشجار. لذلك نثبّت البذرة العشوائية (seed) للحصول على نتائج قابلة للتكرار.

س: لاحظنا أن أرقام صفحة 24 تختلف عن أرقام الملخص. ما تفسيرك؟

ج: نعم، هذا موجود فعلاً في الرسالة: الملخص والاستنتاج يذكران 96.79% للدقة، وصفحة 24 تذكر 96.33% لنفس مجموعة Spambase. أعرض التعارض بوضوح في التطبيق دون تعديل، لأن الأمانة العلمية تقتضي عدم إخفائه. والمجموعة الأقرب للصحة هي مجموعة الملخص لأنها مذكورة في موضعين.

س: كيف يبدو منحنى التقارب، وماذا يعني كل جزء منه؟

ج: على Spambase تنخفض الكلفة بانتظام وعلى شكل درجات خلال التكرارات العشرين: تبدأ حول 2.2e-3، ثم قفزات كبيرة نسبياً سببها المكوّن الجيني (التقاطع والطفرة) الذي يرفع التنوّع، ثم ميل ألطف في المنتصف وهي مرحلة التوازن، وبعد نحو 17 تكراراً تستقر حول 1e-3. وعلى Phishing يكون الهبوط حاداً في البداية ثم يستقر من نحو التكرار التاسع. هذا يعني أن البحث وازن بين استكشاف واسع في البداية وتركيز في النهاية وتجنّب التذبذب العشوائي.

س: هل تتحقق فرضياتك فعلاً؟ كيف تثبتها؟

ج: نعم، والتطبيق يثبتها رقمياً: يقارن التجربة مجموعة السمات المختارة بنتيجة استخدام كل السمات على نفس التقسيم ونفس البذرة، ويعرض الفرق في الدقة والإحكام والاستدعاء و F1 والمساحة تحت المنحنى، إضافة إلى مقدار تقليل عدد السمات وزمن التدريب. فتظهر الفرضيات الثلاث الأولى مُختبَرة على تجربة المستخدم نفسه لا مجرد نص مقتطف.

أسئلة عن المصنّف

س: لماذا اخترت الغابة العشوائية وليس مصنّفاً آخر؟

ج: لأنها تجمع بين دقة عالية ومقاومة للإفراط في التعلّم. فهي تعتمد مستويين من العشوائية: عيّنة عشوائية بإرجاع لكل شجرة، ومجموعة فرعية عشوائية من السمات في كل عقدة. هذا يقلّل الارتباط بين الأشجار ويرفع قوة النموذج. كما أنها تعمل جيداً مع البيانات العددية والوصفية دون معالجة إضافية معقّدة.

س: كيف تصنّف الغابة العشوائية عيّنة جديدة؟

ج: تمرّ العيّنة عبر كل الأشجار، وكل شجرة تعطي صوتاً لفئة. ثم نأخذ الأغلبية. ونسبة الأشجار التي صوّتت للفئة الفائزة هي الثقة التي يعرضها التطبيق.

س: كم شجرة استخدمت؟

ج: 100 شجرة في النموذج النهائي، وفي دالة اللياقة داخل الخوارزمية 50 شجرة لتسريع التقييم.

أسئلة عن التطبيق

س: كيف يعرف التطبيق أن بريداً إلكترونياً مزيف؟

ج: يقرأ نص البريد ويحوّله إلى سمات Spambase السبع والخمسين بالتعريف نفسه الذي استُخدم في بناء البيانات: تكرار كل كلمة من الكلمات الثماني والأربعين كنسبة مئوية من عدد الكلمات، وتكرار كل محرف من المحارف الستة كنسبة من عدد المحارف، ومتوسط وأطول وأكبر مجموع لأطوال سلاسل الأحرف الكبيرة. ثم يمرّر هذا المتجه على الغابة العشوائية المدربة، فتصوّت 100 شجرة، والقرار هو الأغلبية.

س: كيف يعرف التطبيق أن موقعاً مزيفاً؟

ج: يستخرج سمات «Phishing Websites» الثلاثين من نص الرابط نفسه: وجود عنوان IP بدل اسم النطاق، طول الرابط، وجود رمز @، وجود شرطتين مائلتين في غير موضعهما، وجود شرطة في اسم النطاق، عدد النطاقات الفرعية، استخدام HTTPS، وجود كلمة https داخل اسم النطاق، المنفذ غير القياسي، ونطاق النطاق المسجّل مقابل جدول نطاقات موثوقة. ثم يمرّر المتجه على الغابة العشوائية.

س: ما معنى «الثقة» التي يعرضها التطبيق؟

ج: هي نسبة الأشجار المئة التي اتفقت على الفئة الفائزة. فإن عرض 98% فمعناه أن 98 شجرة من 100 صوّتت للفئة نفسها.

س: ما الذي لا يستطيع التطبيق فعله؟

ج: لا يفتح مرفقات البريد، ولا يقرأ ترويسات SMTP، ولا يفحص سمعة المرسل. ولا يجلب صفحة الموقع، لذلك سمات مثل الأيقونة وروابط الوسوم ونموذج الإرسال وإعادة التوجيه وأحداث الفأرة لا تُستخرج من الرابط؛ تأخذ القيمة الأغلبية في البيانات، إلا إذا كان النطاق في جدول النطاقات الموثوقة فيأخذ القيمة السليمة. ومؤشرات الثقة مثل عمر النطاق والزيارات وترتيب الصفحة وفهرسة Google وسجل DNS وشهادة SSL تأتي من الجدول نفسه، فلا يُمنح نطاق مجهول أي شك إيجابي. لذلك الناتج مؤشر إحصائي قوي وليس دليلاً قاطعاً.

س: هل التطبيق يعمل دون إنترنت؟

ج: نعم، بشكل كامل. مجموعتا البيانات مضمّنتان داخل التطبيق، والنماذج تُدرَّب محلياً، ولا يُجرى أي اتصال شبكي.

س: ما لغات البرمجة المستخدمة في المواد التي سلّمتها؟

ج: اللغة الوحيدة الموجودة في الرسالة والمجلد المضغوط هي MATLAB. الملفات main.m و GA_PSO_feature_selection.m و fitness_RF.m و repair_solution.m و plot_results.m تستخدم دوال MATLAB مثل TreeBagger و randperm و perfcurve و confusionchart. أما هذا التطبيق فقد أعدت كتابته بلغة Python مع مكتبة scikit-learn، خطوة بخطوة، بنفس دالة الكلفة ونفس تحديثات PSO و GA ونفس المقاييس، ليعمل كملف تنفيذي واحد على ويندوز دون الحاجة إلى MATLAB.

س: هل يمكنني رؤية شيفرة MATLAB الأصلية داخل التطبيق؟

ج: نعم. صفحة شيفرة MATLAB تعرض الملفات الخمسة الأصلية كما هي حرفياً دون أي تعديل، مع ترتيب تنفيذها ووصف وظيفة كل ملف، وتضم أيضاً ملفات .fig الأصلية التي أنتجت صور النتائج وملف main.asv. وصفحة أشكال الرسالة تعرض الصور التسع المصدَّرة من MATLAB كما هي، وبجانبها القيم المنشورة في الرسالة، حتى تقارنها بمنحنيات التطبيق المحسوبة.

أسئلة عن المعالجة المسبقة

س: كيف عالجت القيم المفقودة؟

ج: بطريقة الجيران الثلاثة الأقرب بمعامل K يساوي 3: لكل عيّنة فيها قيمة مفقودة نجد أقرب ثلاث عيّنات في فضاء السمات، ونقدّر القيمة المفقودة من متوسط القيمة نفسها عند هذه العيّنات.

س: لماذا التطبيع؟

ج: لأن سمات البيانات تختلف في المدى اختلافاً كبيراً: بعضها نسبة مئوية بين 0 و100، وبعضها عدد صحيح قد يصل إلى آلاف. بدون تطبيع، السمة ذات المدى الكبير تهيمن على حسابات المسافة والتشابه. التطبيع Min-Max (المعادلة 3-1) يعيد كل سمة إلى المجال من 0 إلى 1.

س: لماذا قسمة البيانات إلى تدريب واختبار؟

ج: لأن تقييم النموذج على البيانات التي تدرب عليها يعطي نتيجة مضلّلة ومتفائلة. مجموعة الاختبار لا تُلمَس إلا في النهاية، فتكون النتيجة تقديراً صادقاً لقدرة النموذج على التعميم.

أسئلة محتملة صعبة

س: ما نقاط ضعف طريقتك؟

ج: أولاً، الكلفة الحسابية: تدريب الغابة العشوائية داخل دالة اللياقة مكلف، ويزداد الأمر مع كبر حجم البيانات. ثانياً، بعض سمات مجموعة المواقع لا يمكن استخراجها من الرابط وحده فتحتاج جلب الصفحة. ثالثاً، الخوارزمية عشوائية، فالنتائج تتغيّر قليلاً مع البذرة.

س: لو أردت تحسين العمل، ماذا ستفعل؟

ج: أستخدم تحققاً متقاطعاً حقيقياً داخل دالة اللياقة بدل التقييم على بيانات التدريب نفسها، وأضيف مصنّفات أخرى للمقارنة مثل XGBoost و SVM، وأجعل عدد السمات المطلوب يُستنتج تلقائياً بدل تثبيته، وأختبر على بيانات أحدث.

س: كيف تثبت أن نتيجتك ليست صدفة؟

ج: بثلاثة أمور: أولاً، التجربة على مجموعتين مختلفتين تماماً أعطت نتائج متسقة. ثانياً، تثبيت البذرة العشوائية يعطي نتائج قابلة للتكرار. ثالثاً، مقارنة استخدام كل السمات باستخدام السمات المختارة تُظهر أن التحسّن ناتج عن الاختيار وليس عن الصدفة.

س: ما الفرق بين اختيار السمات (feature selection) واستخلاص السمات (feature extraction)؟

ج: اختيار السمات يُبقي مجموعة فرعية من السمات الأصلية كما هي، فتبقى قابلة للتفسير: نعرف أن سمة «تكرار كلمة free» مهمة. أما استخلاص السمات فينشئ سمات جديدة مدمجة، مثل PCA، فلا تبقى قابلة للتفسير بالطريقة نفسها. رسالتي تستخدم الاختيار لأنه يحافظ على معنى السمات.

س: لماذا لا تستخدم طريقة مرشّح (filter) بسيطة مثل معلومات متبادلة؟

ج: لأن طرق المرشّح تقيّم كل سمة بمعزل عن غيرها، وتتجاهل التفاعل بين السمات. طريقتنا تغلّف (wrapper) تُقيّم المجموعة كاملة بالمصنّف الفعلي، فتكتشف أن سمتين قد تكونان ضعيفتين منفردتين لكنهما قويتان معاً. الثمن هو الوقت، لكن النتيجة أدق.

عدد الأسئلة: 40. كل الأجوبة مستخرجة من نص الرسالة ومن الشيفرة المرافقة لها، ولا تخالف أي رقم منشور فيها.